

Sesión 7 – Calidad de Datos y Validación Final del Dataset

Objetivo

Evaluar la calidad de un dataset después del proceso de limpieza y elaborar un **Data Cleaning Report** que documente los hallazgos, correcciones y nivel de confianza de los datos.

Pregunta de apertura

Mostrar la siguiente situación:

Analista

| "Ya terminé de limpiar el archivo."

Jefe/Lider

| "¿Cómo lo sabes?"

Normalmente responderíamos:

- Porque ya no vi errores.
- Porque revisé algunas filas.
- Porque eliminé los duplicados.

En el ámbito profesional:

| En el mundo real no basta con decir que los datos están limpios. Debemos demostrarlo.

¿Qué es la Calidad de Datos?

La calidad de datos mide qué tan confiable es la información para tomar decisiones.

Las 5 dimensiones principales



1 Completitud

¿Los datos están completos?

Ejemplo:

Nombre	Ciudad
Juan	Bogotá
Ana	

Problema:

Falta información.

2 Consistencia

¿Los datos siguen el mismo formato?

Ejemplo:

```
Bogotá  
bogotá  
BOGOTÁ  
Bogota
```

Problema:

Representan lo mismo pero aparecen diferentes.

3 Validez

¿Los datos cumplen las reglas?

Ejemplo:

```
Edad = -5
```

Problema:

Valor imposible.

4 Exactitud

¿Los datos reflejan la realidad?

Ejemplo:

```
Edad = 450
```

Aunque Excel lo acepta, probablemente no es correcto.

5 Unicidad

¿Cada registro aparece una sola vez?

Ejemplo:

ID

MU1045

MU1045

Problema:

Duplicado.



Checklist de Validación Final

Antes de declarar el dataset "listo para análisis", todo analista debería responder:

Compleitud

- ☐ No existen columnas críticas vacías.
- ☐ Los valores faltantes fueron tratados.

Consistencia

- ☐ Las categorías están estandarizadas.
- ☐ Los formatos son uniformes.

Validez

- ☐ No existen valores imposibles.
- ☐ Se revisaron los valores fuera de rango.

Unicidad

- ☐ No existen duplicados relevantes.

Documentación

- ☐ Todas las correcciones fueron registradas.
-




Introducción al Data Cleaning Report

Cuando terminamos de limpiar datos debemos dejar evidencia del trabajo realizado.

Ese documento se conoce como:

Data Cleaning Report o Informe de Limpieza de Datos



¿Qué contiene un Data Cleaning Report?

1. Información General

Campo	Valor
Dataset	MoveUp
Fecha	
Analista	
Versión	

2. Resumen Ejecutivo

Ejemplo:

Se realizó un proceso de limpieza sobre el dataset MoveUp con el objetivo de mejorar la calidad de los datos antes de realizar análisis exploratorios. Se identificaron valores faltantes, registros duplicados, inconsistencias de formato y valores fuera de rango.

3. Problemas Encontrados

Problema	Cantidad
Valores faltantes	
Duplicados	
Tipográficos	
Inconsistencias	
Outliers	

4. Acciones Realizadas

Problema	Acción
Duplicados	Eliminados
Espacios extra	Corregidos
Mayúsculas inconsistentes	Estandarizadas
Valores vacíos	Tratados

5. Calidad Antes y Después

Indicador	Antes	Después
Registros		
Vacíos		
Duplicados		
Errores detectados		

6. Riesgos Identificados

Ejemplo:

Algunos registros presentaban valores extremos que podrían requerir una validación adicional con la fuente original.

7. Conclusión

Ejemplo:

El dataset presenta un nivel de calidad adecuado para realizar análisis descriptivos y visualizaciones. Las principales inconsistencias fueron corregidas y documentadas.



Actividad de Cierre

Auditoría Cruzada

Intercambiar datasets entre equipos.

Cada equipo deberá actuar como auditor y responder:

¿El dataset está realmente limpio?

Revisar:

- Valores faltantes
- Duplicados
- Categorías

- Formatos
- Valores fuera de rango

Resultado

Criterio	Cumple
Compleitud	✓ / ✗
Consistencia	✓ / ✗
Validez	✓ / ✗
Unicidad	✓ / ✗



Reflexión Final

| "Un análisis solo es tan bueno como los datos que lo alimentan."

La siguiente unidad o modulo se enfocara en:

```
Recolección de datos
    ↓
Limpieza de datos
    ↓
Validación de calidad
    ↓
Análisis exploratorio
    ↓
Visualización
    ↓
Toma de decisiones
```

La limpieza no termina cuando se corrigen errores en Excel; termina cuando podemos demostrar, mediante un **Data Cleaning Report**, que el dataset está listo para generar información confiable.