

Sesión 5 – Definición de Criterios para la Limpieza de Datos

Esta es una de las cosas más importantes que puede aprender alguien que quiera trabajar en análisis de datos.

La mayoría de los cursos enseñan Excel, Power BI, Python o SQL, pero muy pocos enseñan **cómo pensar cuando los datos están mal**, que es precisamente lo que ocurre en la vida real.

De hecho, en muchas empresas un analista puede dedicar entre el **60% y el 80% del tiempo** limpiando, entendiendo y validando datos antes de hacer un solo gráfico.

La primera verdad incómoda

Los datos nunca son perfectos

Cuando un gerente te entrega un archivo y te dice:

"Aquí están los datos"

Lo que realmente te está entregando es:

Errores humanos.

Errores de digitación.

Procesos mal diseñados.

Sistemas que no validan entradas.

Valores faltantes.

Inconsistencias históricas.

Suposiciones incorrectas.

El trabajo del analista es transformar eso en algo confiable.

El objetivo de la limpieza NO es dejar el dataset bonito

Muchos principiantes creen:

"Voy a corregir todo lo que se vea raro."

El objetivo es:

Maximizar la calidad de los datos sin inventar información.

Principio #1

Nunca inventar datos

Supongamos:

ID	Edad
1	25
2	NULL
3	30

Un principiante podría pensar:

"Pongámosle 27."

Eso es inventar.

Nunca se hace.

Entonces qué se hace con un NULL

Depende. Y aquí empieza el verdadero análisis profesional.

Tipos de problemas

Valores faltantes (Missing Values)

Ejemplos:

NULL

Vacío

N/A

-
Unknown

Pregunta

¿Por qué falta?

Hay una enorme diferencia entre:

Caso A

Caso B

Caso C

Caso D

Cada caso tiene tratamiento distinto.

¿Cuándo eliminar registros?

Nunca como primera opción.

Supongamos:

1000 registros.

10 tienen edad vacía.

Eliminar esos 10 probablemente no cambia nada.

Pero:

100 registros.

40 tienen edad vacía.

Ahora eliminar registros destruye el dataset.

Por eso normalmente se mide:

% de datos faltantes

Ejemplo:

Variable	Nulos
Edad	2%
Ciudad	1%

Variable	Nulos
Salario	75%

Si una variable tiene 75% de nulos:

Tal vez no sirve para análisis.

¿Cuándo imputar?

Imputar significa rellenar.

Ejemplo:

Edad

20

22

NULL

24

Podríamos usar, para la celda null:

Media

22

Mediana

22

Moda

Valor más frecuente

Pero esto se hace con mucho cuidado.

Siempre debe documentarse.

Principio #2

Nunca corregir algo solo porque parece raro

Ejemplo:

Edad = 98

Muchos analistas dirían:

"Eso está mal."

¿Cómo lo sabes?

Tal vez es una persona de 98 años.

En cambio:

Edad = -5

Eso sí es imposible.

Aquí aparece otro concepto.

Reglas de Negocio (Business Rules)

¿Quién define las reglas?

Muchos creen que el analista, pero no es así, estas reglas son definidas por el negocio en si mismo.

Ejemplo: Trabajas para una universidad.

Pregunta: ¿Cuál es la edad válida?

Tú no decides de forma directa, validas o preguntas con las áreas involucradas:

Registro académico.

Admisiones.

Coordinación.

Ellos responden:

Entre 14 y 90 años.

Ahora tienes una regla.

Entonces

Edad = 120

Viola la regla.

Edad = 98

No necesariamente.

Principio #3

Diferenciar error de dato atípico

Ejemplo:

Ingresos mensuales

1500000

1800000

2200000

1750000

95000000

¿95 millones es error?

Tal vez sí.

Tal vez no.

Quizás es el gerente.

Un dato atípico no es automáticamente incorrecto.

Tipos de errores más comunes

Errores de formato

Bogotá

bogota

BOGOTA

Bogota

Representan la misma ciudad.

Se estandariza.

Bogotá

Errores tipográficos

Medelln

Medelin

Medellín

Normalización.

Medellín

Duplicados

Ejemplo:

ID	Nombre
1	Ana
1	Ana

¿Es realmente duplicado?

Hay que investigar.

Muchas veces:

Cliente compra dos veces

No es duplicado.

Son dos eventos distintos.

Principio #4

Antes de borrar algo, entender qué representa una fila

Esto es clave.

Si una fila representa:

Persona

Un ID debería aparecer una vez.

Si una fila representa:

Compra

El mismo cliente puede aparecer 100 veces.

Por eso primero:

¿Qué representa la fila?

Luego:

¿Qué representa la columna?

Y solo después:

¿Qué está mal?

El proceso profesional real

Paso 1

Comprender el negocio

Preguntas:

¿Qué representa cada fila?

¿Qué representa cada columna?

¿Quién genera estos datos?

¿Para qué se usan?

Paso 2

Perfilado de datos (Data Profiling)

Explorar.

Para cada columna:

Tipo de dato.

Nulos.

Mínimos.

Máximos.

Valores únicos.

Distribución.

Ejemplo:

Variable	Tipo
Edad	Numérica
Ciudad	Texto
Registro	Fecha

Paso 3

Definir reglas de calidad

Ejemplo:

Edad:

$18 \leq \text{edad} \leq 100$

Ciudad:

Debe pertenecer al catálogo oficial

Fecha:

No puede ser futura

Paso 4

Clasificar problemas, cada error recibe categoría.

Tipo

Nulo

Duplicado

Formato

Valor inválido

Inconsistencia

Outlier

Paso 5

Decidir tratamiento, no existe una solución universal.

Para cada problema decides:

Problema	Acción
Nulo	Conservar
Nulo	Imputar
Nulo	Eliminar
Formato	Corregir
Duplicado	Consolidar
Valor inválido	Marcar
Valor inválido	Eliminar

Paso 6

Documentar todo

Esto es donde muchos fallan.

Cada cambio debe quedar registrado.

Ejemplo:

Fecha	Campo	Regla	Acción
22/06/2026	Ciudad	Normalización	Bogotá → Bogotá
22/06/2026	Edad	Valor inválido	-2 → NULL

Si alguien pregunta:

"¿Por qué desaparecieron 300 registros?"

Debes poder responder.

Regla de oro que enseñan los equipos maduros

Nunca modifiques el dataset original.

Mantén siempre:

01_raw_data

Datos originales.

02_cleaned_data

Datos limpios.

03_analysis

Análisis.

Porque tarde o temprano alguien dirá:

"Creo que la limpieza eliminó algo importante."

Y necesitarás volver atrás.

Cómo piensa un analista senior

Un junior suele preguntar:

"¿Cómo arreglo este dato?"

Un senior pregunta:

"¿Por qué apareció este error?"

Porque el verdadero objetivo no es limpiar una vez.

Es encontrar qué proceso, sistema o persona está generando datos defectuosos para que el problema deje de ocurrir.

Ahí es donde el análisis de datos deja de ser Excel y se convierte en mejora de procesos y toma de decisiones basada en evidencia.

Actividad: Limpieza del Dataset MoveUp

Objetivo

Aplicar las técnicas de limpieza de datos aprendidas en clase para identificar y documentar problemas de calidad presentes en el dataset **MoveUp**, dejando los datos listos para futuros análisis.

Dataset

Archivo:

MoveUp_Dataset.xlsx

65.3 KiB

Paso 1: Conocer el Dataset

Antes de modificar cualquier dato, responde:

Preguntas iniciales

¿Cuántas filas tiene el dataset?

¿Cuántas columnas tiene?

¿Qué representa cada fila?

¿Qué representa cada columna?

¿Qué variables son numéricas?

¿Qué variables son categóricas?

¿Qué variables podrían representar fechas o tiempos?

Paso 2: Identificar Problemas de Calidad

2.1 Valores Faltantes

Busca:

Celdas vacías

Información incompleta

Datos ausentes

Registro de hallazgos

Columna	Cantidad de valores faltantes

2.2 Registros Duplicados

Busca:

Filas idénticas

Participantes repetidos

Registro

¿Existen registros duplicados?

¿Cuántos encontraste?

¿Qué harás con ellos?

2.3 Errores de Escritura

Busca ejemplos como:

Cali / cali / CALI

Bogotá / Bogota

Medellín / Medellin

Ejemplos encontrados

Valor original	Valor corregido

2.4 Formatos Inconsistentes

Busca diferencias en:

Mayúsculas y minúsculas

Espacios adicionales

Abreviaturas

Formatos de respuesta

Ejemplos encontrados

Problema encontrado	Corrección aplicada

2.5 Valores Atípicos o Fuera de Rango

Busca datos que parezcan poco realistas.

Ejemplos:

Edad negativa

Horas de sueño superiores a 24

Tiempo de pantalla exageradamente alto

Valores imposibles para alguna variable

Casos encontrados

Variable	Valor encontrado	¿Por qué es problemático?